



BLOQUE 1 · SESIÓN 2 DE 24

# Tipos de datos, fuentes y arquitectura

Del origen al modelo de datos

Curso: Inteligencia de Negocios y Power BI · 120h · 24 sesiones

## SESIÓN 2

# ¿Qué veremos hoy?

- ▶ Tipos de datos: estructurados, semiestructurados y no estructurados
- ▶ Fuentes de datos empresariales: ERP, CRM, APIs, ficheros planos
- ▶ Formatos de archivo: CSV, Excel, JSON, XML, bases de datos
- ▶ Calidad del dato: los 4 problemas más frecuentes
- ▶ El modelo relacional: tabla, registro, campo, clave
- ▶ El esquema estrella: la base de Power BI
- ▶ Ejercicio guiado: identificar el modelo en datos reales

📌 **Conexión con la sesión anterior:** En la Sesión 1 vimos que el BI convierte datos en decisiones. Hoy aprendemos *de dónde vienen esos datos* y cómo deben estar organizados para que Power BI funcione bien.

PARTE 1 DE 3

# Tipos y fuentes de datos

No todos los datos son tablas

## TIPOS DE DATOS

# 3 tipos de datos en el mundo real

### □ Estructurados

Organizados en filas y columnas.  
Fáciles de analizar directamente.

- Tablas en bases de datos SQL
- Hojas de Excel / Google Sheets
- Archivos CSV
- Exportaciones de ERP o CRM

### □ Semiestructurados

Tienen estructura interna pero no en forma de tabla fija.

- JSON (respuestas de APIs)
- XML (facturas electrónicas)
- Emails con formato estándar
- Logs de aplicaciones

### □ No estructurados

Sin estructura predefinida. Son el 80% de los datos del mundo.

- Correos electrónicos (texto libre)
- Imágenes y vídeos
- Documentos PDF / Word
- Grabaciones de audio

En Power BI trabajaremos principalmente con datos **estructurados**. Power Query puede procesar algunos semiestructurados (JSON, XML). Los no estructurados requieren herramientas de IA o procesamiento especializado.

## FUENTES DE DATOS

# ¿De dónde vienen los datos en una empresa?

| Fuente                           | ¿Qué contiene?                                   | Formato habitual                     |
|----------------------------------|--------------------------------------------------|--------------------------------------|
| <b>ERP</b> (SAP, Odoo, Sage)     | Ventas, compras, contabilidad, producción, stock | Base de datos SQL, exports CSV/Excel |
| <b>CRM</b> (Salesforce, HubSpot) | Clientes, oportunidades, interacciones, pipeline | API REST (JSON), exports CSV         |
| <b>Ficheros Excel/CSV</b>        | Exportaciones manuales de cualquier sistema      | XLSX, CSV                            |
| <b>Base de datos propia</b>      | Datos operacionales de la aplicación             | SQL (MySQL, PostgreSQL, SQL Server)  |
| <b>APIs externas</b>             | Redes sociales, clima, tipo de cambio, logística | JSON, XML                            |
| <b>Google Analytics / Ads</b>    | Tráfico web, conversiones, campañas              | API, exports CSV                     |

📌 **Realidad de las empresas:** La mayoría tiene datos en *múltiples fuentes simultáneamente*. El trabajo del analista BI incluye unificarlos en un modelo coherente antes de visualizar.

## Formatos que encontrarás en el trabajo

### □ CSV (Comma Separated Values)

Texto plano con valores separados por comas. Universal, ligero, sin formato. El más frecuente en exports.

```
id,nombre,importe  
1,Ana,1250.00  
2,Carlos,890.00
```

### □ Excel (XLSX)

Hojas de cálculo con formato, fórmulas y múltiples pestañas. Muy común pero puede tener inconsistencias de formato.

### □ JSON

Formato de intercambio entre aplicaciones (APIs). Jerárquico, flexible. Power Query puede aplanarlo a tabla.

```
{"id":1,"nombre":"Ana",  
  "importe":1250.00}
```

### □ Base de datos SQL

MySQL, PostgreSQL, SQL Server, SQLite. Los datos más estructurados y fiables. Power BI se conecta directamente mediante conector nativo.

PARTE 2 DE 3

# Calidad del dato

El problema más frecuente en proyectos BI reales

## Las 4 dimensiones de calidad del dato

### □ Completitud

Campos vacíos o registros incompletos.

**Ejemplo:** Tabla de clientes donde el 30% no tiene email. O pedidos sin fecha de entrega.

### □ Consistencia

El mismo valor expresado de formas distintas.

**Ejemplo:** "Madrid", "madrid", "MADRID", "Md." en la misma columna ciudad.

### □ Unicidad

Registros duplicados que inflan las métricas.

**Ejemplo:** El mismo cliente aparece dos veces con distinto ID tras una migración.

### □ Actualidad

Datos desactualizados que distorsionan el análisis.

**Ejemplo:** Precios de 2 años atrás usados en un análisis de margen actual.



## EJERCICIO DE DETECCIÓN

# ¿Cuántos problemas encuentras?

Abre `clientes_datos_sucios.csv` en Excel. Identifica todos los problemas antes de ver las respuestas.

**DUPLICADO** Fila 1 y Fila 5: Ana López aparece dos veces con datos idénticos.

**DUPLICADO** Fila 4 y Fila 16: TechOffice SA / TechOffice, S.A. — mismo cliente, nombre diferente.

**CONSISTENCIA** Ciudad en minúsculas ("barcelona", "san sebastián", "tarragona") mezclada con mayúsculas.

**CONSISTENCIA** Segmento: "particular", "PYME", "Pyme", "empresa" — mismos valores escritos diferente.

**COMPLETITUD** Fila 3: email vacío. Fila 8: nombre vacío. Fila 10: email vacío.

**ACTUALIDAD** Fila 6: fecha 2024-02-29 no existe (2024 es bisiesto ✓ — pero hay que comprobarlo).

**CONSISTENCIA** Fila 13: fecha en formato DD-MM-YYYY en lugar de YYYY-MM-DD.

**COMPLETITUD** Fila 9: importe negativo (-150€) — posible error de entrada o devolución sin marcar.

En la **Sesión 5** aprenderemos a corregir todos estos problemas con Power Query de forma automatizada.

PARTE 3 DE 3

# **El modelo relacional**

La base de cómo funciona Power BI

## Los conceptos básicos

### □ **Tabla**

Colección de registros del mismo tipo. Ejemplo: tabla de clientes, tabla de ventas.

### □ **Clave primaria (PK)**

Identificador único de cada registro en una tabla. Nunca se repite. Ejemplo: `id_cliente`.

### → **Registro (fila)**

Una entidad concreta. Ejemplo: la venta número 42, el cliente "Ana López".

### □ **Clave foránea (FK)**

Referencia a la clave primaria de otra tabla. Crea la relación entre tablas. Ejemplo: `id_cliente` en la tabla de ventas.

### ↓ **Campo (columna)**

Un atributo de la entidad. Ejemplo: nombre, importe, fecha.

## ¿Por qué no poner todo en una sola tabla?

### ✗ Tabla única (desnormalizada)

- El nombre del cliente se repite en cada venta → miles de duplicados
- Cambiar el nombre de un producto requiere actualizar 500 filas
- Inconsistencias imposibles de detectar
- Tablas de millones de filas lentas e inmanejables

### ☐ Varias tablas relacionadas

- Cada entidad se guarda una sola vez
- Cambiar un producto se actualiza en un solo lugar
- Menos datos almacenados, más rápido
- Fácil de mantener y ampliar

Power BI está diseñado para trabajar con **múltiples tablas relacionadas**. Entender esto es clave para construir modelos correctos en las sesiones siguientes.

## El esquema estrella (Star Schema)



### Tabla de Hechos

Contiene los **números** (importe, cantidad, coste). Una fila = una transacción. Puede tener millones de filas.

### Tablas de Dimensiones

Contienen el **contexto** (quién, qué, cuándo, dónde). Pocas filas. Se conectan a la tabla de hechos por clave.

## Hechos vs. Dimensiones: la diferencia clave

□ **Analogía del ticket de caja:** el ticket registra *qué pasó* (compré 2 auriculares por 59,90€). El catálogo te dice *qué es* ese producto. El calendario te dice *cuándo fue*. El ticket solo = hechos. Ticket + catálogo + calendario = análisis completo.

□ TABLA DE HECHOS — ventas

| id_venta | id_prod | id_cliente | cantidad | importe  |
|----------|---------|------------|----------|----------|
| V001     | P003    | C012       | 2        | 59,90 €  |
| V002     | P001    | C007       | 1        | 349,99 € |
| V003     | P003    | C025       | 3        | 89,85 €  |

□ Contiene los **NÚMEROS que quieres medir** (cantidad, importe, coste...). Una fila = un evento que ocurrió. Solo guarda IDs, nunca los nombres.

□ TABLA DE DIMENSIÓN — productos

| id_prod | nombre           | categoría   | precio   |
|---------|------------------|-------------|----------|
| P003    | Auriculares BT   | Audio       | 29,95 €  |
| P001    | Monitor 27" 4K   | Monitores   | 349,99 € |
| P002    | Teclado Mecánico | Periféricos | 89,50 €  |

□ Contiene las **ETIQUETAS que dan contexto** (nombre, categoría, región...). Pocas filas. Convierte los IDs en algo que los humanos entienden.

□ **La magia de la relación:** la venta V001 en solitario solo dice "P003, 2 uds, 59,90€". Al cruzarla con la dimensión Productos, Power BI sabe que P003 = "Auriculares Bluetooth, categoría Audio". **Los hechos miden. Las dimensiones explican.**

EJERCICIO GUIADO



# Práctica

Identificar el modelo en datos reales

## EJERCICIO GUIADO

# Identifica el esquema estrella

Tienes 4 archivos CSV en la carpeta `ejercicios/` :

### **ventas.csv**

id\_venta, id\_fecha, id\_producto, id\_cliente, id\_vendedor,  
cantidad, importe...

### **productos.csv**

id\_producto, nombre\_producto, categoria, precio\_base,  
coste\_unitario...

### **clientes.csv**

id\_cliente, nombre\_cliente, region, segmento, ciudad,  
email...

### **fechas.csv**

id\_fecha, fecha, dia, mes, nombre\_mes, trimestre, anyo...

## Tareas:

- ▶ ¿Cuál es la tabla de hechos? ¿Cuáles son las dimensiones?
- ▶ Identifica la clave primaria (PK) de cada tabla
- ▶ Identifica las claves foráneas (FK) en la tabla de ventas
- ▶ Dibuja en papel el esquema estrella con flechas



## REFLEXIÓN FINAL

# Preguntas para reflexionar

- ▶ ¿Por qué es mejor tener los datos en varias tablas relacionadas que en una sola tabla gigante?
- ▶ ¿Qué problemas concretos puede causar la mala calidad del dato en un análisis de ventas?
- ▶ ¿Cómo afecta tener datos de fuentes diferentes con formatos distintos?
- ▶ Si un cliente aparece duplicado con dos IDs distintos, ¿qué pasa con las métricas de ventas por cliente?

**Para la próxima sesión (Sesión 3):** Aprenderemos a definir KPIs correctamente, diseñar dashboards y hacer wireframing.



# **¡Hasta la próxima sesión!**

Sesión 3: KPIs, métricas y diseño de informes

En la Sesión 3 trabajaremos con los datos de la empresa del curso.